

# Introduction à la sémantique des langages de programmation

Adrien Guatto

Compilation M1

## Quoi ?

- Mathématiser des concepts essentiels des langages de programmation.
- Implémenter ces concepts en OCaml, le cas échéant.

## Pourquoi ?

- Acquérir les notions et la terminologie de base du domaine.
- Comprendre les sujets des prochains jalons du projet.
- Se préparer à vos futurs cours de sémantique (par exemple, au S2).

## Quel rôle pour Marthe ?


- Beaucoup plus simple qu'OCaml, Java, Python, ou le  $\lambda$ -calcul.
- Exhibe pourtant certaines difficultés caractéristiques.
- Peut être progressivement étendu en un langage plus riche.

Cours 1

# Syntaxe et sémantique de Marthe

# Contexte : les compilateurs

Un compilateur traduit un langage source vers un langage cible.



Un compilateur doit avant tout être **correct**. Qu'est-ce que cela signifie ?

# Correction des compilateurs, dans l'abstrait

Quelques notations :

- $|\mathcal{S}|$  désigne l'ensemble des *termes* du langage source,
- $|\mathcal{T}|$  désigne l'ensemble des termes du langage cible,
- $C : |\mathcal{S}| \rightarrow |\mathcal{T}|$  désigne le compilateur, fonction de  $|\mathcal{S}|$  dans  $|\mathcal{T}|$ .

Intuitivement, on aimerait adopter une définition ressemblant à :

$C$  est correct  $\stackrel{\text{def}}{=} \forall M \in |\mathcal{S}|, M$  et  $C(M)$  “font la même chose”.

C'est un peu vague. Essayons :

$C$  est correct  $\stackrel{\text{def}}{=} \forall M \in |\mathcal{S}|, M$  et  $C(M)$  ont le **même résultat**.

Chaque langage  $L \in \{\mathcal{S}, \mathcal{T}\}$  doit donc définir le **résultat**  $R_L(M)$  de tout terme  $M \in |L|$ . On obtient donc, formellement :

$C$  est correct  $\stackrel{\text{def}}{=} \forall M \in |\mathcal{S}|, R_{\mathcal{S}}(M) = R_{\mathcal{T}}(C(M))$ .

# La sémantique de Marthe (1/3)

Comment définir **mathématiquement** le langage Marthe, noté  $\mathcal{M}$  ?

- $|\mathcal{M}|$  est l'ensemble des **arbres de syntaxe abstraite** de Marthe, décrits sous la forme d'une grammaire BNF au premier cours.

$$|\mathcal{M}| \ni M, N, P ::= x \mid \underline{n} \mid M \pm N \mid M \ast N \mid \sum_{x=M}^N P$$

- Pour définir  $R_{\mathcal{M}}$ , on va reformuler notre **interprète** écrit en OCaml sous la forme d'un ensemble de triplets appelé *Eval*.

$$(M, \sigma, n) \in Eval \Leftrightarrow "M \text{ s'évalue en } n \text{ dans l'environnement } \sigma"$$

- En OCaml, un environnement est une liste de couples variable/entier. Et en sémantique ? Un choix commode : les fonctions **partielles finies**.

$$Env \stackrel{\text{def}}{=} \{ \sigma : Var \rightarrow \mathbb{N} \mid \sigma^{-1}(\mathbb{N}) \text{ est fini} \}$$

- Le résultat d'un terme Marthe est l'**ensemble des entiers vers lesquels il s'évalue dans l'environnement vide** :

$$R_{\mathcal{M}}(M) \stackrel{\text{def}}{=} \{ n \in \mathbb{N} \mid (M, \emptyset, n) \in Eval \}.$$

# La sémantique de Marthe (2/3)

Que doit contenir notre ensemble de triplets  $Eval \subseteq |\mathcal{M}| \times Env \times \mathbb{N}$ ?

- Le terme  $\underline{n}$  doit s'évaluer en  $n$  dans tout  $\sigma$ .

$$\{(\underline{n}, \sigma, n) \mid n \in \mathbb{N}, \sigma \in Env\} \subseteq Eval$$

- Le terme  $x$  doit s'évaluer en  $v$  dans  $\sigma$  **si**  $\sigma(x) = v$ .

$$\{(x, \sigma, \sigma(x)) \mid x \in Var, \sigma \in Env\} \subseteq Eval$$

- Le terme  $M \pm N$  doit s'évaluer en  $m + n$  dans  $\sigma$  **si**  $M$  s'évalue en  $m$  dans  $\sigma$  et  $N$  s'évalue en  $n$  dans  $\sigma$ . De même pour  $\underline{*}$ .

$$\{(M \pm N, \sigma, m + n) \mid (M, \sigma, m), (N, \sigma, n) \in Eval\} \subseteq Eval$$

$$\{(M \underline{*} N, \sigma, mn) \mid (M, \sigma, m), (N, \sigma, n) \in Eval\} \subseteq Eval$$

- **[Exercice]** Déterminer les contraintes pour  $\sum_{x=M}^N P$ .

# La sémantique de Marthe (3/3)

Au moins deux approches possibles pour  $\sum_{x=M}^N P$ .

- 1 Un seul cas : évaluer  $P$  sur la plage complète en une seule fois.

$$\left\{ \left( \sum_{x=M}^N P, \sigma \right) \mid (M, \sigma, m), (N, \sigma, n) \in Eval, \forall m \leq i \leq n, (P, \sigma[x \mapsto i], p_i) \in Eval \right\} \subseteq Eval$$

- 2 Deux cas : évaluer  $P$  itération par itération.

$$\{ (\sum_{x=M}^N P, \sigma, 0) \mid (M, \sigma, m), (N, \sigma, n) \in Eval, n < m \} \subseteq Eval$$

$$\left\{ (\sum_{x=M}^N P, \sigma, p+r) \mid (M, \sigma, m), (N, \sigma, n), (P, \sigma[x \mapsto m], p), (\sum_{x=M \pm 1}^N P, \sigma, r) \in Eval, m \leq n \right\} \subseteq Eval$$

Les deux approches sont *mathématiquement* équivalentes.



# Fabriquer la sémantique (1/2)

On a obtenu un ensemble de contraintes sur notre ensemble *Eval*.

$$\{(\underline{n}, \sigma, n) \mid n \in \mathbb{N}, \sigma \in Env\} \subseteq Eval \quad (1)$$

$$\{(x, \sigma, \sigma(x)) \mid x \in Var, \sigma \in Env\} \subseteq Eval \quad (2)$$

$$\{(M \pm N, \sigma, m + n) \mid (M, \sigma, m), (N, \sigma, n) \in Eval\} \subseteq Eval \quad (3)$$

$$\{(M * N, \sigma, mn) \mid (M, \sigma, m), (N, \sigma, n) \in Eval\} \subseteq Eval \quad (4)$$

$$\left\{ \left( \sum_{x=M}^N P, \sigma, 0 \right) \mid (M, \sigma, m), (N, \sigma, n) \in Eval, n < m \right\} \subseteq Eval \quad (5)$$

$$\left\{ \left( \sum_{x=M}^N P, \sigma, p + r \right) \mid (M, \sigma, m), (N, \sigma, n), (P, \sigma[x \mapsto m], p), \right. \\ \left. (\sum_{x=M \pm 1}^N P, \sigma, r) \in Eval, m \leq n \right\} \subseteq Eval \quad (6)$$

Comment construire un ensemble *Eval* les respectant *exactement*?

- En appliquant le théorème de Knaster-Tarski.
- En le construisant à la main, cf. transparent suivant.

# Fabriquer la sémantique (2/2)

L'idée : construire une séquence croissante d'ensembles  $Eval_k$  pour  $k \in \mathbb{N}$ .

$$Eval_0 = \{(\underline{n}, \sigma, n) \mid n \in \mathbb{N}, \sigma \in Env\} \cup \{(x, \sigma, \sigma(x)) \mid x \in Var, \sigma \in Env\}$$

$$Eval_1 = Eval_0 \cup \{(M \pm N, \sigma, m + n) \mid (M, \sigma, m), (N, \sigma, n) \in Eval_0\}$$

$$\cup \{(M * N, \sigma, mn) \mid (M, \sigma, m), (N, \sigma, n) \in Eval_0\}$$

$$\cup \left\{ \left( \sum_{x=M}^N P, \sigma, 0 \right) \mid (M, \sigma, m), (N, \sigma, n) \in Eval_0, n < m \right\}$$

$$\cup \left\{ \left( \sum_{x=M}^N P, \right. \mid (M, \sigma, m), (N, \sigma, n), (P, \sigma[x \mapsto m], p), \right. \\ \left. \left. \sigma, p + r \right) \mid (\sum_{x=M \pm 1}^N P, \sigma, r) \in Eval_0, m \leq n \right\}$$

$$Eval_{k+1} = Eval_k \cup \{(M \pm N, \sigma, m + n) \mid (M, \sigma, m), (N, \sigma, n) \in Eval_k\} \cup \dots$$

La séquence  $(Eval_k)_{k \in \mathbb{N}}$  converge vers le  $Eval$  qu'on cherche à construire.

Il suffit donc de poser comme définition :

$$Eval \stackrel{\text{def}}{=} \bigcup_{k \in \mathbb{N}} Eval_k.$$

# Présentation alternative de la sémantique

Il est commode d'adopter une notation infixe pour  $Eval$ .

$$\boxed{M; \sigma \Downarrow n} \stackrel{\text{def}}{=} (M, \sigma, n) \in Eval \Leftrightarrow \exists k \in \mathbb{N}, (M, \sigma, n) \in Eval_k$$

Ensuite, on peut montrer que  $M; \sigma \Downarrow n$  est vrai si et seulement c'est la racine d'un arbre dont les noeuds sont étiquetés par les règles ci-dessous.

$$\begin{array}{c} \frac{}{n; \sigma \Downarrow n} \qquad \frac{}{x; \sigma \Downarrow \sigma(x)} \qquad \frac{M; \sigma \Downarrow m \quad N; \sigma \Downarrow n}{M \pm N; \sigma \Downarrow m + n} \\[2ex] \frac{M; \sigma \Downarrow m \quad N; \sigma \Downarrow n}{M * N; \sigma \Downarrow mn} \qquad \frac{M; \sigma \Downarrow m \quad N; \sigma \Downarrow n}{\sum_{x=M}^N P; \sigma \Downarrow 0} \quad n < m \\[2ex] \frac{M; \sigma \Downarrow m \quad N; \sigma \Downarrow n \quad P; \sigma[x \mapsto m] \Downarrow p \quad \sum_{x=M \pm 1}^N P; \sigma \Downarrow r}{\sum_{x=M}^N P; \sigma \Downarrow p + r} \quad m \leq n \end{array}$$

**[Exercice]** Construire un arbre de racine  $\sum_{x=\underline{1}}^{\underline{2}} x * \underline{3}; \emptyset \Downarrow n$  ( $n$  au choix).

# Jugements inductifs et sémantiques à grands pas

## En pratique

Plutôt que de construire  $(Eval_k)_{k \in \mathbb{N}}$  et  $Eval$  sous forme ensembliste, on préfère définir directement la relation  $M; \sigma \Downarrow n$  par des règles.

- On appelle une telle relation un *jugement inductif* et un arbre de racine  $M; \sigma \Downarrow N$  une *dérivation* de *conclusion*  $M; \sigma \Downarrow N$ .
- Les deux définitions sont équivalentes car  $(M, \sigma, n) \in Eval_k$  si et seulement si  $M; \sigma \Downarrow n$  admet une dérivation de hauteur  $k$ .
- Une sémantique qui associe à un terme son résultat final est dite “à **grands pas**”. On en verra d’autres exemples.
- Celle que nous venons de définir est **déterministe**.

Si  $M; \sigma \Downarrow n$  et  $M; \sigma \Downarrow m$  alors  $m = n$ .

- **[Exercice]** Est-elle **totale** ?

$$\forall M \in |\mathcal{M}|, \forall \sigma \in Env, \exists n \in \mathbb{N}, M; \sigma \Downarrow n$$

# Quand l'évaluation est-elle définie ?

- Il n'existe pas d'entier  $n$  tel que  $x; \emptyset \Downarrow n$ . Donc  $R_{\mathcal{M}}(x) = \emptyset$ .
- Notre sémantique définit donc une fonction partielle de  $|\mathcal{M}| \times Env$  dans  $\mathbb{N}$ , que notre fonction OCaml `eval` implémente.
- **[Exercice]** Quels sont les termes  $M$  tels que  $R_{\mathcal{M}}(M) = \emptyset$  ?
- Pour que l'évaluation d'un terme soit définie, il faut que la valeur de chacune de ses variables  $x$  soit définie. Donc,  $x$  doit :
  - soit appartenir à  $\sigma^{-1}(\mathbb{N})$ ,
  - soit apparaître sous une construction  $\sum_{x=M}^N (-)$  (qui la “lie”).

Comment rendre ces intuitions précises ?

# Variables libres et termes clos

- L'ensemble  $FV(M)$  des *variables libres* d'un terme  $M$  est défini par récursion sur  $M$ .

$$FV(\underline{n}) = \emptyset$$

$$FV(x) = \{x\}$$

$$FV(M \pm N) = FV(M) \cup FV(N)$$

$$FV(M * N) = FV(M) \cup FV(N)$$

$$FV(\sum_{x=M}^N P) = FV(M) \cup FV(N) \cup (FV(P) \setminus \{x\})$$

- Un terme  $M$  est dit *clos* si  $FV(M) = \emptyset$  et *ouvert* sinon.
- **[Exercice]**  $\sum_{x=\underline{1}}^4 x$ ,  $\sum_{x=\underline{1}}^4 y$  et  $(\sum_{y=\underline{1}}^4 y) \pm y$  sont-ils clos ou ouverts ?
- **[Exercice]** Programmer  $FV$  en OCaml.

## Propriété

Il existe  $n \in \mathbb{N}$  tel que  $M; \sigma \Downarrow n$  si et seulement si  $FV(M) \subseteq \sigma^{-1}(\mathbb{N})$ .

# Équivalence observationnelle de termes Marthe

Il semble raisonnable de considérer que deux termes Marthe sont équivalents lorsqu'ils calculent le même entier dans tout environnement.

$$M \equiv N \stackrel{\text{def}}{=} \forall \sigma \in Env, \forall n \in \mathbb{N}, M; \sigma \Downarrow n \Leftrightarrow N; \sigma \Downarrow n$$

Que peut-on dire sur cette relation d'*équivalence observationnelle*?

- Elle est clairement réflexive, symétrique et transitive.
- Elle valide les identités arithmétiques habituelles.

$$(M \pm N) \pm P \equiv M \pm (N \pm P) \quad M \pm N \equiv N \pm M \quad \dots$$

- Elle valide certains renommages de variables.

$$\sum_{x=1}^9 (x * z) \stackrel{?}{=} \sum_{y=1}^9 (y * k) \quad \sum_{x=1}^9 (x * z) \stackrel{?}{=} \sum_{y=1}^9 (y * z)$$

$$\sum_{x=1}^9 \sum_{y=1}^9 (x \pm y) \stackrel{?}{=} \sum_{y=1}^9 \sum_{x=1}^9 (y \pm x) \quad x \pm \sum_{x=1}^9 x \stackrel{?}{=} y \pm \sum_{y=1}^9 y$$

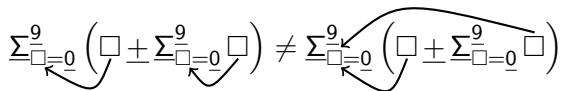
L'égalité à un renommage des variables liées près est une notion universelle dans les langages de programmation : l' **$\alpha$ -conversion**.

# L' $\alpha$ -conversion : intuitions

Une *occurrence* liée n'a pas d'identité : elle ne fait que référence à un lieu.

$$\sum_{x=\underline{0}}^9 \left( x \pm \sum_{x=\underline{0}}^9 x \right) \equiv_{\alpha} \sum_{x=\underline{0}}^9 \left( x \pm \sum_{y=\underline{0}}^9 y \right) \not\equiv_{\alpha} \sum_{x=\underline{0}}^9 \left( x \pm \sum_{y=\underline{0}}^9 x \right)$$

On peut donc voir les termes comme des **graphes de liaison**.



Les graphes de liaison :

- rendent l' $\alpha$ -conversion triviale ( $M \equiv_{\alpha} N$  ssi  $\text{Gr}(M) = \text{Gr}(N)$ ),
- assignent une identité uniquement aux occurrences libres,

$$\text{Gr}\left(\sum_{x=\underline{0}}^9 (x \pm y)\right) = \sum_{\square=\underline{0}}^9 (\square \pm y)$$

- sont utilisés en pratique dans les implémentations efficaces.



# L' $\alpha$ -conversion : renommage des variables libres

On définit  $M[y/x]$ , le renommage de  $x$  en  $y$  dans  $M$ , comme suit.

$$z[y/x] = \begin{cases} y & \text{si } z = x \\ z & \text{sinon} \end{cases}$$

$$\underline{n}[y/x] = \underline{n}$$

$$(M \pm P)[y/x] = M[y/x] \pm P[y/x]$$

$$(M \ast P)[y/x] = M[y/x] \ast P[y/x]$$

$$(\sum_{z=M}^N P)[y/x] = \begin{cases} \sum_{z=M[y/x]}^{N[y/x]} P & \text{si } z = x \\ \sum_{z=M[y/x]}^{N[y/x]} P[y/x] & \text{sinon} \end{cases}$$

Cette définition est-elle raisonnable ? **Non.** [Exercice] Calculer :

$$(\sum_{x=\underline{1}}^9 y)[z/y] = \sum_{x=\underline{1}}^9 z \qquad (\sum_{x=\underline{1}}^9 x)[z/x] = \sum_{x=\underline{1}}^9 x$$

$$(\sum_{x=\underline{1}}^9 y)[x/y] = \sum_{x=\underline{1}}^9 x$$

# L' $\alpha$ -conversion : définition

Il ne faut pas *capturer* de variable libre lors d'un renommage :

$$(\sum_{z=M}^N P)[y/x] = \begin{cases} \sum_{z=M[y/x]}^{N[y/x]} P & \text{si } z = x \\ \sum_{k=M[y/x]}^{N[y/x]} P[k/z][y/x] & \text{sinon} \end{cases}$$

où  $k$  est une variable *fraîche*, au sens où  $k \notin FV(P) \cup \{y\}$ .

L' $\alpha$ -conversion, notée  $\equiv_\alpha$ , est définie comme un jugement inductif.

$$\frac{}{x \equiv_\alpha x} \qquad \frac{}{\underline{n} \equiv_\alpha \underline{n}} \qquad \frac{M \equiv_\alpha M' \quad N \equiv_\alpha N'}{M \underline{+} N \equiv_\alpha M' \underline{+} N'}$$

$$\frac{M \equiv_\alpha M' \quad N \equiv_\alpha N'}{M \underline{*} N \equiv_\alpha M' \underline{*} N'} \qquad \frac{\begin{array}{c} M \equiv_\alpha M' \quad N \equiv_\alpha N' \\ P[z/x] \equiv_\alpha P'[z/y] \quad z \notin FV(P) \cup FV(P') \end{array}}{\sum_{x=M}^N P \equiv_\alpha \sum_{y=M'}^{N'} P'}$$

**[Exercice]** Programmer renommage et test d' $\alpha$ -conversion en OCaml.

# Substitutivité de l'équivalence observationnelle

Quand je programme, je peux toujours remplacer un fragment de code par un autre qui lui est équivalent. Comment rendre cette idée précise ?

$$(\sum_{x=1}^4 \underline{12}) \underline{+} (\underline{3} \underline{*} \underline{2}) \equiv (\sum_{x=1}^4 \underline{12}) \underline{+} (\underline{1} \underline{+} \underline{5})$$

Comment séparer la **partie commune** des **deux termes équivalents** ?

$$((\sum_{x=1}^4 \underline{12}) \underline{+} y) [\underline{3} \underline{*} \underline{2} / y] \equiv ((\sum_{x=1}^4 \underline{12}) \underline{+} y) [\underline{1} \underline{+} \underline{5} / y]$$

Ce  $N[M/x]$  désigne  $N$  où  $M$  a été *substitué* aux occurrences libres de  $x$ .

## Substitutivité de l'équivalence

Pour tout  $M, N_1, N_2, x$ , si  $N_1 \equiv N_2$  alors  $M[N_1/x] \equiv M[N_2/x]$ .

Il nous reste à définir formellement l'opération de substitution.

# Substitution

La substitution généralisant le renommage, on imite sa définition.

$$y[M/x] = \begin{cases} M & \text{si } y = x \\ y & \text{sinon} \end{cases}$$

$$\underline{n}[M/x] = \underline{n}$$

$$(N \pm P)[M/x] = N[M/x] \pm P[M/x]$$

$$(N \ast P)[M/x] = N[M/x] \ast P[M/x]$$

$$\left(\sum_{y=N}^P O\right)[M/x] = \begin{cases} \sum_{z=N[M/x]}^{P[M/x]} O & \text{si } y = x \\ \sum_{z=N[M/x]}^{P[M/x]} O[z/y][M/x] & \text{sinon} \end{cases}$$

où, dans la dernière clause,  $z$  est fraîche, i.e.,  $z \notin FV(O) \cup FV(M)$ .

**[Exercice]** Programmer la substitution en OCaml.



Un langage de programmation est défini par :

- sa **syntaxe**,
  - qui comprend des variables *libres* et des variables *liées*,
  - à laquelle on peut appliquer *renommage* et *substitution*,
  - sur laquelle on raisonne “à renommage des variables liées près” ,
- sa **sémantique**,
  - une relation d'*évaluation* associant programmes et résultats (ici),
  - qu'on peut implémenter comme un interprète écrit en OCaml,
  - à partir de laquelle on peut définir l'*équivalence observationnelle*.

La prochaine séance adaptera ces concepts à une extension de Marthe.

# Pour la prochaine fois



**[Exercice]** Formuler une sémantique équivalente de Marthe utilisant un jugement auxiliaire  $P; \sigma; x; m; n \Downarrow_{\Sigma} p$  pour l'évaluation des sommes.

$$\frac{M; \sigma \Downarrow m \quad N; \sigma \Downarrow n \quad P; \sigma; x; m; n \Downarrow_{\Sigma} p}{\sum_{x=M}^N P; \sigma \Downarrow p}$$

Cette sémantique devra être équivalente aux deux autres.

(*Indice* : il s'agit de reformuler le code OCaml.)